

# ОТЧЁТ О ВЫПОЛНЕНИИ ЗАДАНИЯ

## Поиск частых наборов объектов алгоритмом Apriori

Набор данных: **baskets.csv**

Число транзакций: **7501**

Исследованные пороги: **1%, 3%, 5%, 10%, 15%**

## 1. Формулировка задания

Требуется разработать программу поиска частых наборов объектов в транзакционном наборе данных методом Apriori или его модификацией. Для каждого найденного набора необходимо указать поддержку. Входными параметрами служат набор данных, минимальный порог поддержки и способ сортировки результата: по убыванию поддержки или лексикографически.

Экспериментальная часть должна сравнивать время работы при разных порогах поддержки и показывать число частых наборов разной длины. Результаты необходимо представить диаграммами и объяснить наблюдаемые зависимости.

## 2. Материалы проекта

Исходный код, набор данных и результаты размещены в репозитории: <https://github.com/FeodorG/data-mining-fundamentals>.

## 3. Методика

Реализован классический поуровневый Apriori. На первом шаге подсчитывается поддержка отдельных товаров. Для каждого следующего уровня выполняются объединение частых наборов предыдущей длины, отсечение кандидатов с нечастыми подмножествами и один проход по транзакциям для подсчёта поддержки кандидатов.

Относительная поддержка набора  $X$  вычисляется как

$$\text{support}(X) = \frac{|\{t : X \subseteq t\}|}{N},$$

где  $N$  — число транзакций. Абсолютный порог равен округлённому вверх произведению относительного порога на  $N$ . Время каждого опыта измерялось трижды; далее приведена медиана.

Программа автоматически читает UTF-8 и Windows-1251. Результат сохраняется в CSV с набором, его длиной, абсолютной и относительной поддержкой. Параметр `--order` принимает значения `support` и `lexicographic`.

## 4. Результаты экспериментов

Таблица 1: Сводные результаты, три запуска для каждого порога

| Порог | Медиана, с | Частых наборов | Макс. длина |
|-------|------------|----------------|-------------|
| 1%    | 1.2628     | 261            | 3           |
| 3%    | 0.2019     | 55             | 2           |
| 5%    | 0.1200     | 28             | 2           |
| 10%   | 0.0130     | 7              | 1           |
| 15%   | 0.0087     | 5              | 1           |




Рис. 1: Зависимость медианного времени работы от порога поддержки

## 5. Распределение наборов по длине




Рис. 2: Количество частых наборов; цвет показывает длину набора

Таблица 2: Число наборов каждой длины

| Порог | Длина 1 | Длина 2 | Длина 3 | Всего |
|-------|---------|---------|---------|-------|
| 1%    | 74      | 170     | 17      | 261   |
| 3%    | 36      | 19      | 0       | 55    |
| 5%    | 25      | 3       | 0       | 28    |
| 10%   | 7       | 0       | 0       | 7     |
| 15%   | 5       | 0       | 0       | 5     |

## 6. Интерпретация

При повышении порога множество допустимых наборов монотонно сокращается: с 261 при 1% до 5 при 15%. Это прямое следствие определения частого набора: более строгому порогу удовлетворяет меньше товаров и комбинаций.

На пороге 1% преобладают пары (170 из 261), а также появляются 17 троек. При 3% остаются 19 пар, при 5% — только 3 пары. Начиная с 10% частыми являются лишь одиночные товары. Следовательно, совместные покупки имеют заметно меньшую поддержку, чем самые популярные отдельные товары.

Низкий порог сохраняет больше наборов на каждом уровне, поэтому Apriori генерирует и проверяет существенно больше кандидатов. При высоких порогах процесс завершается уже после уровня одиночных товаров. Небольшие колебания времени между запусками объясняются состоянием операционной системы.

## 7. Вывод

Разработанная программа выполняет поиск частых наборов, рассчитывает абсолютную и относительную поддержку и поддерживает оба требуемых порядка сортировки. Эксперименты показывают ожидаемый компромисс: низкий порог позволяет выявить больше сложных сочетаний, но увеличивает вычислительные затраты; высокий порог оставляет только наиболее массовые товары и резко ускоряет поиск.