

ОТЧЁТ ПО ЛАБОРАТОРНОЙ РАБОТЕ

Классификация с помощью дерева решений

Набор данных	UCI Adult (Census Income)
Целевая переменная	Годовой доход: $\leq 50\,000$ или $> 50\,000$ долларов
Критерии	Information Gain, Gain Ratio, Gini Index
Дата формирования	25 сентября 2026 г.

Исходный код, данные и результаты находятся в каталоге проекта lab3.

1. Формулировка задания

- Разработать программу классификации набора данных деревом решений с критериями Information Gain, Gain Ratio и Gini Index.
- Провести эксперименты на Census Income, используя 100% исходной обучающей выборки для построения дерева.
- Визуализировать построенные деревья решений.
- Добавить параметр доли обучающей выборки и вычисление accuracy, precision, recall и F-меры.
- При фиксированном критерии провести эксперименты для соотношений 60:40, 70:30, 80:20 и 90:10.
- Построить диаграмму зависимости показателей качества от соотношения выборок и объяснить результаты.

2. Исходные материалы

Набор Adult содержит социально-демографические признаки жителей и бинарную метку дохода. В исходной обучающей части 32 561 запись, в тестовой — 16 281 запись; всего 48 842. Категориальное значение «?» сохранено как отдельная категория, а точка в конце меток файла adult.test удалена при загрузке.

<https://github.com/FeodorG/data-mining-fundamentals/tree/main/lab3>

Оригинал набора: [UCI Machine Learning Repository — Adult](#).

3. Метод решения

Дерево строится рекурсивно. Для числового признака перебираются пороги, сформированные по квантилям; для категориального — бинарные проверки равенства категории. Выбирается разбиение с наибольшим значением критерия. Ограничения глубины и минимального размера листа уменьшают переобучение и время расчёта.

Information Gain: $IG = H(S) - \sum((|S_i|/|S|) H(S_i))$.

Gain Ratio: $GR = IG / \text{SplitInfo}$.

Gini gain: $DG = \text{Gini}(S) - \sum((|S_i|/|S|) \text{Gini}(S_i))$.

Положительным классом считается доход > 50K. Метрики вычисляются по TP, TN, FP и FN: accuracy — доля всех верных ответов; precision — доля верных среди предсказанных положительных; recall — доля найденных положительных; F1 — гармоническое среднее precision и recall.

Параметры эксперимента

Параметр	Значение
max_depth	8
min_samples_split	200
min_samples_leaf	80
max_thresholds	32
random seed	42

4. Сравнение критериев

Каждое дерево обучено на всех 32 561 записях adult.data и проверено на независимых 16 281 записях adult.test.

Критерий	Accuracy	Precision	Recall	F1
Information Gain	0,851	0,764	0,536	0,630
Gain Ratio	0,849	0,769	0,515	0,617
Gini Index	0,851	0,769	0,524	0,624

Information Gain показал максимальные accuracy (0,851) и F1 (0,630). Gain Ratio немного повысил precision до 0,769, но снизил recall до 0,515. Все модели существенно хуже находят положительный класс, чем обеспечивают общую ассигуру: это связано с дисбалансом классов, поскольку доля >50K составляет примерно 24%.

4.1. Дерево: Information Gain

На рисунке показаны первые четыре уровня. Узел содержит условие, число наблюдений, долю положительного класса и прогноз. Ветвь yes соответствует выполнению условия; цвет обозначает прогнозируемый класс.




Рисунок 1. Верхние уровни дерева, критерий Information Gain.

4.2. Дерево: Gain Ratio

На рисунке показаны первые четыре уровня. Узел содержит условие, число наблюдений, долю положительного класса и прогноз. Ветвь yes соответствует выполнению условия; цвет обозначает прогнозируемый класс.




Рисунок 2. Верхние уровни дерева, критерий Gain Ratio.

4.3. Дерево: Gini Index

На рисунке показаны первые четыре уровня. Узел содержит условие, число наблюдений, долю положительного класса и прогноз. Ветвь **yes** соответствует выполнению условия; цвет обозначает прогнозируемый класс.




Рисунок 3. Верхние уровни дерева, критерий Gini Index.

5. Влияние размера обучающей выборки

Для этого эксперимента официальные части объединены, после чего выполнено стратифицированное разбиение с фиксированным seed = 42. Критерий зафиксирован: Gini Index. При каждом соотношении дерево обучалось заново.

Обучение:тест	Обучение	Тест	Accuracy	Precision	Recall	F1
60:40	29305	19537	0,851	0,761	0,551	0,639
70:30	34188	14654	0,847	0,755	0,533	0,625
80:20	39073	9769	0,848	0,748	0,547	0,632
90:10	43957	4885	0,841	0,724	0,544	0,621




Рисунок 4. Зависимость показателей качества от соотношения обучающей и тестовой выборок.

Увеличение доли обучения не привело к монотонному росту качества. Ассигасу менялась в узком диапазоне 0,841–0,851. Наибольший F1 (0,639) наблюдался при 60:40. При 90:10 precision снизилась до 0,724. Это объясняется сочетанием трёх факторов: различным составом тестовых частей, дисбалансом классов и ограничением сложности дерева. Меньшая тестовая выборка также даёт менее устойчивую оценку. Поэтому по одному разбиению нельзя утверждать, что 60% данных принципиально лучше 90%; для строгого сравнения нужна повторная кросс-валидация.

6. Выводы

Разработана самостоятельная программа дерева решений с тремя критериями выбора разбиения и параметром доли обучающей выборки. Реализованы очистка Adult, стратифицированное разбиение, расчёт accuracy, precision, recall и F1, экспорт структуры дерева и визуализация результатов.

На официальном разбиении лучшим по accuracy и F1 оказался Information Gain. Общая accuracy около 85% заметно выше recall положительного класса (около 52–54%), поэтому одной accuracy недостаточно для оценки модели на несбалансированных данных. Эксперимент с долями подтверждает, что увеличение обучающей части само по себе не гарантирует улучшения результата при фиксированной сложности дерева и единственном случайном разбиении.

7. Состав каталога

adult_tree.py — реализация дерева и CLI; run_experiments.py — полный эксперимент; data/ — исходные файлы Adult; results/ — таблицы, JSON-структуры и рисунки; requirements.txt — зависимости; README.md — инструкция запуска; report/ — данный отчёт.